

Previsão do índice de sustentabilidade com foco no desempenho ecológico utilizando Machine Learning

Pedro Henrique Rodrigues Salzani
pedro.salzani789@al.unieduk.com.br

Orientador: Prof. André Mendeleck

20 de novembro de 2025

1 Resumo

Este estudo aborda a aplicação de técnicas de aprendizado de máquina na previsão do índice de sustentabilidade de empresas e na interação humana com modelos de linguagem (LLM's). Atualmente, muitos procedimentos de auditoria são realizados com pouco auxílio de ferramentas para validação de dados, sendo realizada manualmente por especialistas, um processo que consome tempo e está sujeito a pequenas incertezas e subjetividades. A proposta consiste em desenvolver um software preditivo baseado em dados ESG (Ambientais, Sociais e de Governança), com ênfase na dimensão ambiental ('E'), com o objetivo de auxiliar investidores na identificação de empresas comprometidas com a sustentabilidade e com práticas ecológicas responsáveis. Para isso, implementamos e comparamos o desempenho de diferentes algoritmos de Machine Learning, incorporando a interação humano-computador com um modelo de linguagem adaptado para as demandas da pesquisa. Os resultados demonstram a eficácia dos modelos de Machine Learning em prever o índice de sustentabilidade com alta precisão, oferecendo uma ferramenta valiosa para complementar, otimizar e validar o trabalho dos auditores.

2 Abstract

This study addresses the application of machine learning techniques in predicting the sustainability index of companies and in human interaction with language models (LLMs). Currently, many audit procedures are performed with little assistance from data validation tools, being carried out manually by specialists, a time-consuming process subject to small uncertainties and subjectivities.

The proposal consists of developing predictive software based on ESG (Environmental, Social and Governance) data, with an emphasis on the environmental dimension ('E'), with the aim of assisting investors in identifying companies committed to sustainability and responsible ecological practices. To this end, we implemented and compared the performance of different Machine Learning algorithms, incorporating human-computer interaction with a language model adapted to our needs. The results demonstrate the effectiveness of the models in predicting the sustainability index with high accuracy, offering a valuable tool to complement, optimize and validate the work of auditors.

3 Introdução

A crescente relevância das práticas de Sustentabilidade, Governança e Ambiental (ESG) no cenário corporativo global tem direcionado o olhar de investidores para métricas que vão além do desempenho financeiro. No Brasil, o Índice de Sustentabilidade Empresarial (ISE B3) serve como um importante balizador, reunindo empresas listadas na bolsa com as melhores práticas de gestão responsável [1]. Criado em 2005, o ISE não apenas referencia investimentos sustentáveis, mas também incentiva as companhias a aprimorarem suas políticas ESG.

Neste contexto, o estudo propõe uma abordagem inovadora para a predição da sustentabilidade empresarial, com ênfase nas práticas ambientais de cada companhia, evidenciando sua relevância no desenvolvimento social e econômico. Exploramos o uso de modelos de Machine Learning para analisar dados, antecipar o resultado de desempenho das empresas com relação ao

seu Índice de Sustentabilidade, oferecendo mais uma ferramenta de apoio à tomada de decisão para investidores, gestores e auditores. Para a interface, incorporamos o uso de um modelo de linguagem, o gemma-2b-it [2], onde seu papel é interagir com o usuário e prover informações sobre o ISE B3 e derivados.

4 Desenvolvimento teórico

A abordagem metodológica deste estudo baseia-se na aplicação de três modelos distintos de Machine Learning para a análise dos dados: Árvore de Regressão 4.8, a Rede Perceptron Multicamadas (MLP) 4.7 e o XGBoost 4.6, escolhidos por suas diferentes arquiteturas, capacidades de modelagem e predição. Para avaliação dos modelos de Machine Learning, utilizaremos as métricas R^2 , MSE e MAE.

A aplicação destes métodos, solicita a utilização de datasets que agregue os parâmetros intrínsecos e típicos, incorporando as características, singularidades e particularidades do problema em análise. Para o treinamento, utilizou-se um conjunto completo de features disponíveis em dataset específico. O pré-processamento dos dados incluiu a codificação de variáveis categóricas para garantir a compatibilidade entre os modelos. Especificamente, o One-Hot Encoding 4.5 foi aplicado aos dados de entrada da MLP, enquanto o Label Encoding foi utilizado para a Árvore de Regressão e o XGBoost. Para a interface interativa (chatbot), foi realizado o Fine-Tuning do modelo Gemma-2b-it, no qual refinamos seu conhecimento acerca do tema proposto.

4.1 Fluxo do sistema de predição




Figura 1: flow

Conforme ilustrado na Figura 1, o fluxo da implementação inicia com o carregamento do dataset de treino. Em seguida, os dados passam por todas as técnicas de encoding mencionadas anteriormente. Com os dados já tratados, realiza-se o treinamento inicial dos modelos. Após isso, a interface do usuário é carregada, pronta para receber os inputs. Além da interface de entrada, o usuário conta com um módulo conversacional baseado no modelo de linguagem Gemma-2B-IT. Esse chatbot tem como função principal auxiliar na utilização do sistema, fornecendo informações sobre o ISE B3, explicando variáveis do dataset e esclarecendo dúvidas sobre os parâmetros e resultados das predições.

Quando o usuário preenche todos os campos necessários, os dados são enviados para a etapa de predição. Em seguida, o sistema inicia um ciclo de decisão: se o resultado não for aceito, o fluxo retorna à fase de entrada de dados, aguardando uma nova submissão. Caso o usuário aprove a predição, as informações de entrada e o resultado são incorporados ao dataset original.

Vale ressaltar que os modelos só serão re-treinados com o novo conjunto de dados na próxima inicialização do software.

4.2 Modelo de Linguagem e Fine-Tuning do Chatbot

O Gemma é um conjunto de modelos de linguagem open-source desenvolvido pela Google [3], que incorpora técnicas de ponta em Large Language Models (LLMs) para diversas aplicações. Trata-se de uma arquitetura text-to-text, capaz de receber uma entrada textual e gerar texto como saída. Nesta pesquisa, optou-se pelo Gemma-2B-IT devido ao seu tamanho reduzido, que possibilita a execução local em computadores e notebooks de desempenho aceitáveis. Para o processo de fine-tuning, foi utilizado um dataset sintético contendo amplo conteúdo contextual sobre o Índice de Sustentabilidade Empresarial (ISE B3) e a Bolsa de Valores do Brasil. Vale ressaltar que o Gemma-2b-it é originalmente um modelo treinado na língua inglesa, então toda interação neste trabalho será na mesma.

4.3 Métricas de avaliação

4.3.1 MAE

O Erro Médio Absoluto (MAE) [13] é uma métrica que avalia o desempenho de modelos de regressão em machine learning. Ela mede a média da diferença absoluta entre os valores previstos pelo modelo e os valores observados, sendo que valores mais próximos de zero indicam melhor desempenho preditivo.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - p_i|$$

Onde:

- n é o número de amostras
- y é o valor observado para cada amostra
- p é o valor previsto pelo modelo para cada amostra
- $||$ representa o valor absoluto

4.3.2 MSE

O Erro Quadrático Médio (MSE) [14] é uma métrica crucial em regressão e aprendizado de máquina para avaliar o desempenho de modelos preditivos. Ele mede a média das diferenças ao quadrado entre os valores previstos e os reais, indicando o quão próximas as previsões estão da realidade. Assim como a MAE, valores mais próximos de zero indicam melhor desempenho preditivo.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Onde:

n = Número de pontos de dados
 Y_i = Valores Observados
 Y = Valores previstos

4.3.3 R²

O R² (ou coeficiente de determinação) [15] é uma métrica usada para medir o quão bem um modelo se ajusta aos dados e quão bem ele prevê resultados futuros. Valores próximos a 1 indicam que o modelo possui alta capacidade explicativa, enquanto valores próximos a 0 sugerem baixo poder preditivo.

$$R^2 = 1 - \frac{SSE}{SST}$$

Onde:

SSE = Soma dos Quadrados dos Erros
 SST = Soma dos Resíduos Quadrados

4.4 LabelEncoder

O LabelEncoder [7] é uma técnica de pré-processamento que converte variáveis categóricas em valores numéricos inteiros. Cada categoria recebe um número único, facilitando seu uso em algoritmos de machine learning que exigem dados numéricos.

Seja:

$$C = \{c_1, c_2, c_3, \dots, c_n\}$$

O LabelEncoder define uma função:

$$f(c_i) = i - 1, \quad \text{para } i = 1, 2, \dots, n$$

atribuindo a cada categoria um valor inteiro único.

4.5 OneHotEncoder

O One Hot Encoder [6] transforma variáveis categóricas em vetores binários, criando uma coluna para cada categoria. Cada observação recebe valor 1 na coluna da sua categoria e 0 nas demais, evitando relação ordinal entre os dados.

Seja:

$$C = \{c_1, c_2, \dots, c_n\}$$

O OneHotEncoder define uma função:

$$f : C \rightarrow \{0, 1\}^n$$

tal que, para qualquer $c_i \in C$:

$$f(c_i) = (0, 0, \dots, 1, \dots, 0)$$

onde o valor 1 está na i -ésima posição, e todos os demais valores são 0.

Por exemplo, se $C = \{A, B, C\}$, então:

$$f(A) = (1, 0, 0), \quad f(B) = (0, 1, 0), \quad f(C) = (0, 0, 1)$$

4.6 XGBoost

XGBoost (eXtreme Gradient Boosting) [8] é uma poderosa biblioteca de aprendizado de máquina que se baseia no algoritmo de reforço de gradiente (Gradient Boosting). Essa técnica constrói um modelo preditivo de forma aditiva, combinando uma série de árvores de decisão fracas (weak learners).

Como Funciona?

O princípio central do XGBoost é o reforço de gradiente, que melhora as previsões do modelo passo a passo. O processo ocorre da seguinte forma:

1. Um primeiro modelo, chamado de modelo base, é treinado. Este modelo é tipicamente uma árvore de decisão simples, que por si só não é muito precisa.
2. O algoritmo calcula os resíduos, que são a diferença entre os valores reais e as previsões do modelo base:

$$r_i = y_i - \hat{y}_i$$

3. Uma nova árvore de decisão é treinada para prever esses resíduos, e não os valores originais.
4. A previsão da nova árvore é adicionada à previsão da árvore anterior, e o processo se repete:

$$\hat{y}_i^{(t+1)} = \hat{y}_i^{(t)} + \eta \cdot h_t(x_i)$$

onde η é a taxa de aprendizado e h_t é a nova árvore treinada.

Esse processo continua até que o modelo atinja um desempenho satisfatório, com o objetivo de minimizar a função de perda (loss function), que mede a discrepância entre as previsões do modelo e os valores reais.

4.7 Perceptron Multi Camadas




Figura 2: Multi Layer Perceptron network.

A Rede Perceptron de Multi Camadas [10] é um tipo de rede neural artificial composta por, no mínimo, três camadas: uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída. Cada neurônio em uma camada está conectado a todos os neurônios da próxima camada, formando uma rede densamente conectada.

O MLP utiliza funções de ativação não lineares, como ReLU ou Sigmoide, permitindo que o modelo aprenda relações complexas e não lineares nos dados. O treinamento é realizado por meio do algoritmo de retropropagação (*backpropagation*), que ajusta os pesos da rede minimizando o erro entre a saída prevista e o valor real.

ReLU

A função ReLU é definida por:

$$f(x) = \max(0, x)$$

Ela ativa apenas valores positivos, tornando a rede mais eficiente e mitigando o problema do gradiente desvanecente nas camadas ocultas.

Sigmoid

A função sigmoide é dada por:

$$f(x) = \frac{1}{1 + e^{-x}}$$

Ela comprime qualquer valor real para o intervalo $(0, 1)$, sendo adequada para representar probabilidades na saída de modelos de classificação binária.

4.8 Árvore de Regressão

Uma árvore de regressão [9] é um modelo de aprendizado supervisionado utilizado para prever valores numéricos contínuos, sendo uma extensão das árvores de decisão. O objetivo do modelo é particionar recursivamente o espaço de entrada em regiões disjuntas, de modo que cada divisão minimize a soma dos quadrados dos resíduos dentro de cada região.




Figura 3: Regression tree.

O processo de construção da árvore, conforme apresentado na figura 3, envolve selecionar, em cada nó, a variável e o ponto de corte que resultam na maior redução da variância do valor alvo. Formalmente, para uma região R_m e valores observados y_i dentro dela, o valor predito $\hat{y}_{R_m}$ é dado pela média dos valores do alvo na região:

$$\hat{y}_{R_m} = \frac{1}{|R_m|} \sum_{i \in R_m} y_i$$

A árvore cresce até que critérios de parada sejam atendidos, como número mínimo de observações em uma folha ou profundidade máxima. Após o treinamento, a predição para uma nova observação é determinada pela região à qual ela pertence, utilizando a média dos valores do alvo dessa região. Árvores de regressão são particularmente úteis para capturar relações não lineares e interações complexas entre variáveis, sem a necessidade de pré-especificar um modelo funcional.

5 Desenvolvimento

5.1 Conjunto de Dados (Dataset)

Para o desenvolvimento deste trabalho, foi utilizado um conjunto de dados focados em parâmetros típicos associados à análise ambiental (Environmental) do conjunto ESG (Environmental, Social and Governance), cujos atributos foram selecionados de relatórios disponibilizados em repositórios públicos. Os dados foram gerados sinteticamente, não correlacionados e ou associados aos valores reais utilizados no cálculo do ISE B3 [1], contudo, não menos relevantes para os objetivos deste trabalho.

5.1.1 Descrição das Features (Atributos)

O dataset é composto por 17 campos/colunas (features), sendo elas:

- **Identificadores:** ‘ID’, ‘EMPRESA’, ‘SETOR’.
- **Métricas Ambientais (E):**
 - ‘USO AGUA’: Consumo de água
 - ‘AREA’: Área total ocupada.
 - ‘AREA RESERVA’: Área de conservação.
 - ‘CO2 EMIT DIR’: Emissões diretas.
 - ‘CO2 EMIT INDIR’: Emissões indiretas.

- ‘CO2 REC’: CO_2 recuperado ou capturado.
 - ‘INSUMO QUIMICO LEG’: Insumos químicos convencionais.
 - ‘INSUMO QUIMICO ORG’: Insumos químicos orgânicos.
 - ‘BIODIVERSIDADE’: Métrica de impacto/promoção da biodiversidade.
 - ‘RESIDUO REC’: Resíduos reciclados/recuperados.
 - ‘RESIDUO COMP’: Resíduos compostados.
 - ‘RESIDUO DESC’: Resíduos descartados.
 - ‘ENERGIA REN’: Energia de fontes renováveis.
- **Variável Alvo (Target):**
 - ‘INDICE SUSTENTABILIDADE’: Target, índice de sustentabilidade empresarial [1].




Figura 4: Histograma dos dados disponibilizados no dataset

Os parâmetros selecionados foram escolhidos por representarem os indicadores mais relevantes para a análise da sustentabilidade ambiental de uma empresa. Além disso, os valores utilizados correspondem (na maioria dos casos) a aqueles tipicamente aplicados em auditorias ambientais, garantindo consistência e confiabilidade na avaliação.

5.2 Tratamento e preparação dos dados para predição

Foram desenvolvidos três fluxos de tratamento, adaptados às características específicas de cada modelo utilizado: Árvore de regressão, Perceptron Multi Camadas (MLP) e XGBoost.

2. Para XGBoost e Árvore de Regressão

Modelos baseados em árvore são menos exigentes quanto ao preparo dos dados. Como as árvores segmentam o espaço das features em intervalos e tomam decisões baseadas em condições de corte (feature $\geq$ valor definido), a escala de valores não importa.

- **Features Categóricas ('SETOR'):** Foi usado o `LabelEncoder`. Diferente do MLP, as árvores não são afetadas pela “falsa ordem” dos números. Elas funcionam encontrando os melhores pontos de corte (ex: `SETOR <= 1.5`). O `LabelEncoder` é, portanto, uma abordagem eficiente que evita aumentar desnecessariamente o número de colunas do dataset.
- **Features Numéricas:** Não foi necessário aplicar o `StandardScaler`. A escala das variáveis não afeta o desempenho da árvore, pois suas decisões de divisão são baseadas em *thresholds*, e não na magnitude absoluta dos valores.

1. Para a Rede Neural (MLP)

Redes neurais exigem um tratamento de dados mais cuidadoso [11], pois suas camadas de “neurônios” realizam transformações matemáticas contínuas. Por exemplo, variáveis em escalas muito diferentes podem afetar a avaliação do modelo, como uma variável em uma escala de 0 a 1 e outra em uma escala de 0 a 1000 podem afetar o cálculo dos gradientes.

- **Features Categóricas ('SETOR'):** Foi usado o `OneHotEncoder`. O `LabelEncoder` (que gera valores como 0, 1, 2) não foi usado porque o MLP interpretaria esses números como tendo uma falsa relação ordinal (assumindo, por exemplo, que o Setor “2” é maior ou o dobro do Setor “1”). O `OneHotEncoder` evita isso, criando colunas binárias independentes que tratam cada categoria sem hierarquia.
- **Features Numéricas:** Foi aplicado o `StandardScaler`. MLPs são sensíveis à escala das features ou variáveis com magnitudes muito diferentes (ex: receita vs. número de funcionários), isso pode prejudicar a convergência do modelo. A normalização (média 0, desvio padrão 1) garante que todas as features contribuam de forma equilibrada.

5.3 Estrutura e treinamento dos modelos de Machine Learning

Esta seção detalha a arquitetura, treinamento e as configurações práticas dos modelos de Machine Learning empregados neste estudo.

5.3.1 XGBoost

A implementação utilizou a biblioteca `xgboost` nativa, em python. Os dados foram formatados na estrutura `DMatrix`, otimizada para o algoritmo:

Algorithm 1 Configuração do XGBoost

Definir XGBoost com:

Objetivo: `reg:squarederror`
Profundidade máxima: 6
Taxa de aprendizado: 0.1
Semente aleatória = 42

Onde:

- **Objetivo: `reg:squarederror`** — Define que o problema é de regressão, e o modelo vai minimizar o erro quadrático médio (MSE) entre as previsões e os valores reais.
- **Profundidade máxima: 6** — Controla a complexidade das árvores. Árvores mais profundas podem capturar padrões mais complexos, mas também podem sobreajustar os dados.
- **Taxa de aprendizado: 0.1** — Determina o quanto cada árvore contribui para a previsão final.

Diferentemente da Rede Neural MLP 5.3.2, esta implementação realiza o seguinte processamento nos dados para predição: a coluna categórica 'SETOR' é codificada via `LabelEncoder` e as colunas 'ID' e 'EMPRESA' são removidas. Os demais inputs são passados sem nenhum processamento para o modelo.

5.3.2 Rede Neural (MLP)

Foi utilizado o `MLPRegressor` da biblioteca `Scikit-learn`, em python. A arquitetura definida consiste em duas camadas ocultas, cada uma com 250 neurônios. A função de ativação selecionada foi a Unidade Linear Retificada (ReLU) 4.7, e o otimizador foi o 'Adam' (adam ajusta os pesos da rede neural de forma adaptativa e eficiente combinando momentum e controle do tamanho dos passos durante o treinamento [12]), configurado para um máximo de 1000 iterações (epochs). Os dados de entrada passaram por um pipeline de pré-processamento (preprocessor) antes da predição, para alinhar ao processamento dos dados de treino. O random state foi fixado em 42 para garantir a reprodutibilidade.

Algorithm 2 Configuração da Rede Neural MLP

Definir rede MLP com:
Camadas ocultas: (250, 250)
Função de ativação: ReLU
Otimizador: Adam
Número máximo de iterações: 1000
Semente aleatória = 42

5.3.3 Árvore de regressão

Utilizou-se a implementação DecisionTreeRegressor (Scikit-learn) em python, com random state fixado em 42.

Algorithm 3 Configuração da Árvore de regressão

Definir Árvore de regressão com:
Semente aleatória = 42

O modelo foi treinado por 100 rodadas (equivalente a 100 árvores). Assim como o XGBoost 5.3.1, as colunas 'ID', 'EMPRESA' e 'INDICE SUSTENTABILIDADE' são removidas na passagem dos dados para a predição, e a coluna 'SETOR' também é processada via LabelEncoder.

5.4 Fine-Tuning do Gemma-2b-IT

Para o processo de Fine-Tuning, o modelo Gemma-2B-IT foi quantizado em 4 bits utilizando o formato NF4 (Normal Float 4), com o objetivo de reduzir o uso de memória e viabilizar o treinamento em hardware de menor capacidade. Em seguida, o modelo foi preparado com as técnicas PEFT (Parameter-Efficient Fine-Tuning) e LoRA (Low-Rank Adaptation), que permitem ajustar apenas uma fração dos parâmetros originais, preservando o conhecimento prévio do modelo base e reduzindo o custo computacional. O treinamento supervisionado foi conduzido com o SFTTrainer, ferramenta que facilita o Fine-Tuning de LLMs a partir de exemplos de entrada e saída, garantindo maior estabilidade e controle sobre as métricas de perda durante o processo de otimização.

5.4.1 Dataset

Para o treinamento do modelo de linguagem, foi utilizado um dataset sintético contendo informações relevantes sobre o tema e áreas correlatas. Essa escolha metodológica decorreu da escassez de dados rotulados disponíveis sobre sustentabilidade corporativa e índices ESG, o que tornou a criação de um dataset sintético e específico a abordagem mais adequada para o problema estudado. O dataset foi desenvolvido com o auxílio de modelos de inteligência artificial generativa consolidados, especificamente o GPT (OpenAI) e o Gemini (Google). A estrutura adotada foi o formato JSON, totalizando aproximadamente 7.000 entradas de dados.

A estrutura de entrada dos dados compreende três elementos principais. A chave "instruction" contém a pergunta ou comando que será apresentado ao modelo. A chave "input" permanece vazia, uma vez que o objetivo do treinamento consiste em capacitar o modelo a responder perguntas diretas do usuário, sem a necessidade de itens ou contextos adicionais. Por fim, a chave "output" apresenta a resposta esperada que o modelo deve aprender, correspondente ao contexto estabelecido pela pergunta formulada na instrução.

Listing 1: Exemplo de entrada do dataset sintético

```
{
  "instruction": "What is the ISE B3 index?",
  "input": "",
  "output": "The Corporate Sustainability Index (ISE B3) is an ESG-focused
            index by B3 designed to measure how sustainably-minded companies
            perform in the market."
}
```

5.4.2 LoRA

A LoRA (Low-Rank Adaptation) [4] é uma técnica de fine-tuning eficiente que permite adaptar grandes modelos de linguagem a novos contextos sem re-treiná-los completamente. Em vez de ajustar todos os parâmetros, a LoRA congela os pesos originais e adiciona pequenas matrizes de baixa classificação que aprendem as novas adaptações. Isso reduz drasticamente o custo computacional e de memória, mantendo o desempenho do modelo base. Essencialmente, funciona como um “adaptador leve” que ajusta o modelo a tarefas específicas de forma rápida e eficiente.

5.4.3 PEFT

O PEFT (parameter efficient fine tuning) [5] permite adaptar um modelo já treinado a novas tarefas sem precisar reprocessar todos os seus parâmetros. Em vez disso, apenas uma pequena parte do modelo é ajustada, enquanto o restante permanece congelado. Isso torna o processo de fine-tuning muito mais rápido, leve e eficiente, reduzindo o uso de memória e poder computacional, sem comprometer significativamente o desempenho do modelo.

5.4.4 Configuração da LoRA

A configuração da LoRA foi definida com os seguintes parâmetros:

Algorithm 4 Configuração da LoRA

```
1:  $r \leftarrow 64$ 
2:  $\text{lora\_alpha} \leftarrow 32$ 
3:  $\text{target\_modules} \leftarrow$  lista de camadas lineares identificadas
4:  $\text{lora\_dropout} \leftarrow 0.05$ 
5:  $\text{bias} \leftarrow \text{"none"}$ 
6:  $\text{task\_type} \leftarrow \text{"CAUSAL\_LM"}$ 
7:  $\text{lora\_config} \leftarrow \text{LoraConfig}(r, \text{lora\_alpha}, \text{target\_modules}, \text{lora\_dropout}, \text{bias}, \text{task\_type})$ 
8:  $\text{model} \leftarrow \text{get\_peft\_model}(\text{model}, \text{lora\_config})$ 
```

onde:

- **r (Rank):** Define a dimensão da decomposição de baixa classificação aplicada às matrizes de peso. Valores maiores aumentam a capacidade de adaptação do modelo, mas também elevam o custo computacional.
- **lora_alpha (Alpha):** Fator de escala aplicado às atualizações aprendidas pela LoRA. Controla a intensidade da adaptação, funcionando como um multiplicador que ajusta o impacto das matrizes de baixa classificação nos pesos originais.
- **target_modules:** Especifica as camadas lineares do modelo onde a LoRA será aplicada. Essa seleção direciona o ajuste fino apenas para partes específicas da arquitetura, economizando memória e processamento.
- **lora_dropout:** Taxa de *dropout* aplicada às camadas LoRA durante o treinamento, utilizada para evitar *overfitting* e melhorar a generalização do modelo.
- **bias:** Indica se os termos de viés (*bias terms*) serão treináveis ou não. No caso de “none”, os vieses permanecem congelados e não são atualizados durante o *fine-tuning*.
- **task_type:** Define o tipo de tarefa a ser executada. No contexto de modelos de linguagem autoregressivos, como o Gemma, utiliza-se “CAUSAL_LM”, que corresponde a *Causal Language Modeling*, ou modelagem de linguagem causal.

5.4.5 Configuração do Treinamento

Os parâmetros de treinamento foram definidos por meio da classe `TrainingArguments`, da biblioteca `transformers`, que permite configurar aspectos fundamentais do processo de Fine-Tuning, como tamanho do *batch*, taxa de aprendizado, estratégia de salvamento e avaliação do modelo. Entre os principais hiperparâmetros utilizados, estão:

Algorithm 5 Configuração do treinamento

```
1:  $batch\_size \leftarrow 8$   
2:  $gradient\_accumulation\_steps \leftarrow 1$   
3:  $learning\_rate \leftarrow 2e - 4$   
4:  $lr\_scheduler\_type \leftarrow cosine$   
5:  $fp16 \leftarrow True$ 
```

onde:

- **batch-size:** Número de amostras processadas por dispositivo em cada iteração de treinamento.
- **gradient_accumulation_steps:** Quantidade de etapas de acumulação de gradiente antes da atualização dos pesos, permitindo simular *batches* maiores sem sobrecarregar a memória.
- **learning_rate:** Taxa de aprendizado inicial do otimizador, controlando a magnitude das atualizações dos parâmetros
- **lr_scheduler_type:** Tipo de agendamento da taxa de aprendizado. Neste caso, foi utilizada a estratégia “cosine”, que reduz gradualmente a taxa ao longo das iterações.
- **fp16:** Indica o uso de precisão mista (*float16*) para acelerar o treinamento e reduzir o consumo de memória.

Após a definição desses parâmetros, o modelo, os *datasets* e a configuração da LoRA foram integrados e inicializados no **SFTTrainer**, responsável por conduzir o treinamento supervisionado com base nos pares de instrução e resposta do conjunto sintético.

5.5 Interface da aplicação

A interface de usuário (UI) foi construída com python, utilizando a biblioteca PyQT6.




Figura 5: User Interface

Na implementação, incorporamos uma interface humano-computador através de um chatbot que permite ao usuário interagir com nosso modelo Gemma-2B-IT 4.2 fine-tunado. O modelo foi instruído para responder exclusivamente a perguntas sobre o ISE B3 e a bolsa de valores brasileira, rejeitando consultas fora deste escopo. Por ser originalmente treinado em inglês, todas as interações ocorrem neste idioma. À direita, encontra-se a seção de entrada de dados, onde o

usuário fornece os valores necessários para a predição, organizados por categoria. Após o usuário adicionar os dados e enviar para a predição, temos a seguinte representação:




Figura 6: User interface output

Aqui são exibidas as predições de todos os modelos conforme a inferência do usuário. O usuário pode então selecionar entre salvar todas as predições, salvar uma predição específica, manter o valor original ou descartar todas as predições. Após sua escolha, a interface retorna à tela de entrada de dados.

6 Resultados

Esta seção aborda os resultados obtidos no treinamento dos três modelos de Machine Learning propostos para o problema de regressão: Rede Neural MLP (Multilayer Perceptron), Árvore de Regressão e XGBoost. A performance de cada modelo foi avaliada utilizando as métricas 4.3 de Erro Médio Absoluto (MAE), Erro Quadrático Médio (MSE) e o Coeficiente de Determinação (R^2). Adicionalmente, apresentaremos os resultados do treinamento do modelo de linguagem fine-tunado para o chatbot.

6.1 Protocolo de testes

Para avaliar o desempenho dos modelos propostos, adotou-se a seguinte estratégia de validação: os dados foram divididos em conjunto de treinamento (80%) e conjunto de teste (20%), garantindo uma separação aleatória e representativa das amostras. A avaliação foi conduzida utilizando as métricas Mean Absolute Error (MAE), Mean Squared Error (MSE) e R^2 score, comentadas anteriormente 4.3, implementadas na biblioteca scikit-learn. Para utilizar as respectivas bibliotecas, foi necessário apenas fornecer o conjunto de dados de teste e as predições correspondentes às funções de cálculo.

6.2 Análise Comparativa dos modelos de Machine Learning

Modelo	MAE	MSE	R^2
Regression Tree	0.04174	0.002902	0.6579
MLP	0.04659	0.003470	0.5910
XGBoost	0.02339	0.000863	0.8983

O modelo XGBoost apresentou uma superioridade significativa em todas as métricas avaliadas. Com um R^2 de 0.8983, o XGBoost foi capaz de explicar aproximadamente 89% da variância dos dados, indicando um ajuste muito robusto. Seus indicadores de erro foram os mais baixos, com um MAE de 0.02339 e um MSE de 0.000863. Esses valores são substancialmente menores que os dos outros dois modelos, sugerindo previsões consideravelmente mais precisas. Os modelos Árvore de Regressão e Rede Neural MLP tiveram um desempenho similar entre si, mas notavelmente inferior ao XGBoost. A Árvore de Regressão obteve um R^2 de 0.6579, explicando cerca de 66% da variância, com MAE de 0.04174 e MSE de 0.002902. A Rede Neural MLP apresentou o desempenho mais modesto, com um R^2 de 0.5910 (explicando cerca de 59% da variância) e valores de erro ligeiramente superiores (MAE: 0.04659; MSE: 0.003470).

6.3 Fine Tuning do modelo de linguagem

Para o fine-tuning do modelo de linguagem, obtivemos o seguinte resultado na loss:




Figura 7: llm loss

O loss reduziu de aproximadamente 0.35 para aproximadamente 0.13 em 250 steps, com estabilização a partir do step 100-120, onde a curva atinge um platô que se mantém até o final do treinamento (onde definimos o valor máximo de 250 steps). A convergência foi suave e estável, indicando que o modelo foi adequadamente treinado.

7 Conclusão

Este estudo investigou a aplicação de técnicas de aprendizado de máquina para a previsão do Índice de Sustentabilidade Empresarial (ISE B3), com foco na dimensão ambiental dos critérios ESG. A solução desenvolvida e implementada demonstrou ser uma ferramenta valiosa não apenas para o cálculo do índice de sustentabilidade, mas também pela capacidade de adaptação para diversos processos atualmente realizados de forma manual no contexto econômico brasileiro e global. Ressalta-se, contudo, que a aplicação desta tecnologia deve ocorrer em colaboração com profissionais qualificados, responsáveis pela verificação e validação dos dados, assegurando a confiabilidade e a aplicabilidade prática dos resultados obtidos.

7.1 Modelos utilizados

O **XGBoost** apresentou o melhor desempenho geral, com MAE de 0.02339, MSE de 0.000863 e R^2 de 0.8983. A Árvore de Regressão obteve o segundo lugar com R^2 de 0.6579, MAE de 0.04174 e MSE de 0.002902, evidenciando a efetividade de modelos baseados em árvores para este problema. A rede neural MLP, embora com desempenho aceitável (R^2 de 0.5910), ficou significativamente abaixo dos demais modelos em todas as métricas avaliadas.

7.2 Chatbot

Na implementação proposta, utilizamos o gemma-2b-it [2] como modelo de linguagem natural para humanizar a interação com o usuário e fornecer uma interface de suporte para esclarecer dúvidas pontuais sobre o tema e seus parâmetros. O modelo foi uma escolha acertada por ser leve (possibilitando execução local), compacto e poderoso, características que permitiram um desempenho satisfatório nas tarefas atribuídas. O modelo respeitou as instruções fornecidas e retornou respostas precisas e alinhadas ao seu fine-tuning. Considerando suas limitações, o uso desta solução para o problema em questão mostrou-se eficiente e economicamente viável, justificado pela leveza computacional e poder de processamento adequado.

7.3 Conclusão final

Conclui-se que as técnicas de Machine Learning empregadas, particularmente o XGBoost, integradas a um modelo de linguagem adaptado, constituem uma solução confiável e escalável não apenas para a previsão do Índice de Sustentabilidade Empresarial, mas também para diversos processos econômicos que atualmente demandam tempo considerável e são realizados manualmente. Este trabalho evidencia o potencial transformador da Inteligência Artificial quando adequadamente aplicada, demonstrando como sua adoção estratégica pode otimizar fluxos de trabalho, aumentar a produtividade e elevar a qualidade dos processos de tomada de decisão. Recomenda-se, portanto, que continuemos explorando a capacidade total da IA, aproveitando seu potencial para impulsionar a evolução contínua de práticas profissionais e pessoais.

8 Considerações Finais

8.1 Limitações

Este trabalho apresenta limitações quanto ao poder computacional disponível para treinar e testar modelos de linguagem de maior escala, e à indisponibilidade de dados brutos relacionados ao Índice de Sustentabilidade Empresarial (ISE B3). Além disso, a utilização de um dataset sintético, embora adequado para prova de conceito, não reflete a complexidade e variabilidade dos dados reais de auditoria ambiental. Recomenda-se validação futura com especialistas do domínio.

8.2 Trabalhos Futuros

Sugere-se explorar modelos mais recentes da família Gemma, particularmente o Gemma-3-1b-it [16]. Recomenda-se também migrar a interface para uma tecnologia desktop mais robusta (ex: Electron), ampliando escalabilidade e desempenho. Por fim, propõe-se aprofundar a investigação em algoritmos de Gradient Boosting, explorando variações do XGBoost para comparações futuras.

8.3 Possibilidades de Aplicação

A metodologia desenvolvida é extensível a diversos problemas econômicos e corporativos, tanto no contexto brasileiro quanto global, desde que fundamentados em dados numéricos e enquadrados como problemas de regressão.

8.4 Agradecimentos

Agradeço sinceramente ao Prof. Dr André Mendeleck, que atuou ativamente como mentor durante a redação e desenvolvimento técnico deste trabalho. Agradeço também ao Prof. Romilson Cesar Lima, idealizador do ESG CONFiance, por sua contribuição na concepção inicial desta pesquisa, sendo apresentada no HACKATHON IBRACON 2025, com classificação final em terceira colocação.

Referências

- [1] B3. *Índice de Sustentabilidade Empresarial (ISE B3)*. Disponível em: https://www.b3.com.br/pt_br/market-data-e-indices/indices/indices-de-sustentabilidade/indice-de-sustentabilidade-empresarial-ise-b3.htm. Acesso em: set. 2025.
- [2] Hugging Face *Gemma Model Card*. Hugging Face. Disponível em: <https://huggingface.co/google/gemma-2b-it>.
- [3] Google DeepMind *Visão geral dos modelos Gemma*. Google DeepMind. Disponível em: <https://ai.google.dev/gemma/docs?hl=pt-br>.
- [4] MOREIRA, Sandro. *O que é adaptação de baixa classificação (LoRA)?*. Cloudflare. Disponível em: <https://www.cloudflare.com/pt-br/learning/ai/what-is-lora/9>.
- [5] IBM. *O que é ajuste fino com eficiência de parâmetros (PEFT)?*. IBM. Disponível em: https://www-ibm-com.translate.goog/think/topics/parameter-efficient-fine-tuning?_x_tr_sl=en&_x_tr_tl=pt&_x_tr_hl=pt&_x_tr_pto=tc.
- [6] Scikit-learn. *sklearn.preprocessing.OneHotEncoder*. Documentação oficial. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.OneHotEncoder.html>. Acesso em: jun. 2025.
- [7] Scikit-learn. *sklearn.preprocessing.LabelEncoder*. Documentação oficial. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.LabelEncoder.html>. Acesso em: jun. 2025.
- [8] IBM. *O que é XGBoost?*. Disponível em: <https://www.ibm.com/br-pt/think/topics/xgboost>. Acesso em: set. 2025.
<https://www.ibm.com/docs/pt-br/cognos-analytics/12.0.x?topic=tests-regression-tree>
- [9] IBM. *Árvore de regressão*. Disponível em: <https://www.ibm.com/docs/pt-br/cognos-analytics/12.0.x?topic=tests-regression-tree>
IBM. *O que é XGBoost?*. Disponível em: <https://www.ibm.com/br-pt/think/topics/xgboost>. Acesso em: set. 2025.
- [10] MOREIRA, Sandro. *Rede Neural Perceptron Multicamadas*. Medium, 2018. Disponível em: <https://medium.com/ensina-ai/rede-neural-perceptron-multicamadas-f9de8471f1a9>.
- [11] Anbuazhagan, Saarathi. *A Complete Guide to train Multi-Layered Perceptron Neural Networks*. Medium, 2021. Disponível em: <https://paarthasaarathi.medium.com/a-complete-guide-to-train-multi-layered-perceptron-neural-networks-3fd8145f9498>.
- [12] EITC *Como o otimizador Adam otimiza o modelo de rede neural?*. EITCA, 2023. Disponível em: <https://pt.eitca.org/artificial-intelligence/eitc-ai-dlrf-deep-learning-with-tensorflow/tensorflow/neural-network-model/examination-review-neural-network-model/how-does-the-adam-optimizer-optimize-the-neural-network-model/>.
- [13] MarioFilho *MAE (Erro Médio Absoluto) Em Machine Learning*. Mario Filho, 2023. Disponível em: <https://mariofilho.com/mae-erro-medio-absoluto-em-machine-learning/>.
- [14] Encord *Erro Quadrático Médio (MSE)*. Encord. Disponível em: https://encord-com.translate.goog/glossary/mean-square-error-mse/?_x_tr_sl=en&_x_tr_tl=pt&_x_tr_hl=pt&_x_tr_pto=tc.
- [15] Arize *R ao quadrado: Compreendendo o coeficiente de determinação*. Arize. Disponível em: https://arize-com.translate.goog/blog-course/r-squared-understanding-the-coefficient-of-determination/?_x_tr_sl=en&_x_tr_tl=pt&_x_tr_hl=pt&_x_tr_pto=tc.
- [16] Gemma3 *Gemma 3 model card*. Hugging Face Disponível em: <https://huggingface.co/google/gemma-3-1b-it>.